

从“模型可用” 到“业务可信”

司法风控单据智能校验实践

将不确定的模型输出，转化为可解释、可复核、可持续迭代的业务决策

彭硕

腾讯·风控算法实习生 华中科技大学·网络空间安全

2026.08



INPUT



DECISION



从去年 10 月至今：连续近 11 个月的多模态算法实践

三段经历不是岗位切换，而是一条逐步闭环的成长路径

2025.10 — 2026.03

2026.04 — 2026.05

2026.06 — 至今

京东 AI 安全部

大模型后训练实习生

89 万

多模态 SFT 数据

风险数据构建、多模型投票、Qwen3-VL 全参 SFT 与 GDPO，多目标奖励抑制过度拒答。

训练

京东零售

多模态图像生成算法实习生

F1 95.21%

OCR 选型与部署

商品主图清洗、OCR/VLM 横评、生成效果 Benchmark；从训练转向数据与评测体系。

数据·评测

腾讯

风控算法实习生

4 类

司法单据校验能力

清晰度、文书类型、印章、电话号码；从模型指标进一步走向业务决策闭环。

业务闭环

能力演进

模型训练

数据与评测

任务定义与业务决策

目标：可复用的多模态算法闭环

四类校验能力，服务同一条司法单据有效性链路

01

清晰度五级评估

关键问题

二分类无法表达模糊程度

我的工作

任务重定义 · 弱标注 · VLM 微调

重点项目

02

文书类型识别

关键问题

OCR 错字、旋转与标题错序

我的工作

鲁棒匹配 · 级联路由 · 0.28s/条

重点项目

03

无印章识别

关键问题

浅色/小印章与 2% 负样本

我的工作

三模型融合 · sure/unsure · VLM

横向产出

04

电话号码校验

关键问题

格式混乱且不能误拦

我的工作

提取归一化 · 区号补全 · 硬约束

横向产出

统一命题：风险成本不对称时，如何把不确定信号变成可信决策？

高吞吐、低误拦、可解释：决定了系统必须分层决策

17.4万+

万+ 文书图片 / 日

4

类核心校验任务

低

误拦优先级

误拦真实司法请求的风险通常高于放过存疑样本



模型概率 ≠ 业务风险 | 不确定性不应被强行二分，而应被识别、路由与复核

三个核心模型：按技术难度与答辩篇幅展开

01

重点展开 · 5 页

文书清晰度五级评估

技术难度 ★★★

任务重定义 + 数据构造 + VLM 微调

从二分类双峰分数出发，重建五级序数任务，并构造可训练的数据与模型链路。

02

次重点 · 3 页

无印章识别

技术难度 ★★

多模型融合 + 选择性分类

融合版面、印章检测与视觉先验，通过 sure/unsure 路由控制漏检风险。

03

精简说明 · 2 页

文书类型识别

技术难度 ★

OCR 鲁棒匹配 + 级联

稳定高频类型走快速规则路径，异常样本由 VL 兜底。


篇幅分配遵循技术难度，而不是平均罗列业务需求

文书清晰度五级评估

技术难度最高：原任务没有学习五级质量所需的序数信息

- 01 **问题与关键判断** 为什么二分类分数不能直接切五档
- 02 **任务与数据** 二维可辨识度、弱标注与人工闭环
- 03 **模型架构** Qwen3.5-VL + LoRA + 五级软标签
- 04 **结果与下一步** 过拟合诊断与序数评测体系


ARCHITECTURE PREVIEW



约 6 分钟

关键判断：二分类模型没有学习“模糊程度”，校准也无法补出序数信息

原模型输出



为什么直接切五档不可行？

- 1 训练目标错位** 二分类损失只要求跨过边界，不约束同类内部的质量排序。
- 2 分数不单调** 相近分数可能视觉差异大；视觉相近样本也可能分数差异大。
- 3 校准能力有限** Platt / Isotonic 只能重映射已有信息，不能创造等级 2-4。

因此：先重定义任务与标签，再选择模型。

把“主观清晰度”转化为二维可辨识度，并以人机闭环构造数据

任务定义

$$\text{Quality} = f(\text{unreadable_ratio}, \text{readable_sharpness})$$

不可辨文字比例

决定 Level 3-5

正文中有多少文字已无法辨认

可辨区域锐度

区分 Level 1/2

仍可读文字是否边缘发虚或粘连

只评价正文印刷文字；签名、印章与表格线不计入。

数据闭环

- 1 规则预标注 OCR 行置信度 + 字数/面积权重
- 2 漏检补偿 二值化与连通域估计 OCR 未检文字
- 3 人工校正 标注平台确认五级标签与边界 Case
- 4 训练采样 $1/\sqrt{\text{freq}}$ 缓解 Level 4/5 长尾

训练 9,850 | 测试 3,283 | 独立 AppID

Qwen3.5-VL + LoRA：用五级概率分布学习业务质量标尺



训练目标

文本 Token：Next-Token CE

等级分布：KL / 分布对齐

软标签：以五级有序分布表达相邻等级不确定性，避免边界样本被当作绝对真值。


推理输出

等级 = $\operatorname{argmax} P(L_k)$

连续质量分数 $\hat{q} = \sum p_k \cdot k$

关键设计：不是让 VLM 自由打分，而是把输出限制在可校准的五级概率空间。

训练曲线揭示过拟合：当前瓶颈已转向数据泛化与序数评测

**+56%**

最佳点后 Eval Loss 上涨

结论 1 | 停止增加 epoch

Train Loss≈0.01、Token Acc=0.996，但验证集恶化；继续拟合只会放大噪声。

结论 2 | 重建评测体系

下一步重点看 QWK、MAE、Macro-F1、L4/5 Recall 与概率校准。

项目阶段结论：完成任务定义、数据闭环与模型架构；已定位下一阶段主要矛盾。

无印章识别

技术难度第二：小目标、浅色章与极少负样本共同造成漏检风险

01 模型架构

三路检测信号 + 颜色先验

02 决策与结果

选择性分类 + 切块/VLM 复核



LayoutV2

RT-DETR + Pointer



Layout-L

RT-DETR-L



Seal Detector

ResNet + FPN/PSE



HSV Blob

颜色与几何先验

约 3 分钟

三类模型覆盖不同视觉线索，颜色先验补充浅色印章



融合逻辑 高分直接判有章 | 中分需 Seal/颜色确认 | 低分且无辅助信号判无章 | 其余进入 UNSURE

技术核心不是简单投票，而是让不同模型覆盖版面、弯曲文字与颜色三类互补证据。

选择性分类管理不确定性：先自动处理高置信样本，再升级难例

**100%**

Precision

98.94%

Recall

模型贡献分析

Layout-L 覆盖约 98.5% 的有章检出；V2 独立贡献约 0.2%

下一步：用数据驱动的轻量融合器替代手工阈值，并评估单模型微调。

* Precision / Recall 为高置信自动处理子集口径，正式答辩前与 97.62% 版本统一。

文书类型识别

技术难度第三：核心是把稳定高频模式与长尾异常分开处理

01 级联架构

OCR 快路径 + VL 慢路径

02 关键技术与结果

鲁棒标题匹配, Accuracy 99.99%



约 2 分钟

OCR 快路径 + VL 慢路径：用三层匹配抵抗标题噪声



* 99.99% 正式答辩前补充总样本数、错误数与置信区间。

技术路线由风险、吞吐与确定性共同决定，而不是统一使用大模型

清晰度	VLM 微调	需要学习主观序数标尺
印章	多模型 + VLM 复核	视觉证据互补且漏检成本高
文书类型	OCR 规则 + VL 兜底	高频稳定、长尾复杂
电话号码	正则 + 地理库	高吞吐、可枚举、不能误拦

AI 的三个高杠杆位置

探索

快速验证假设

路由

处理高信息增益难例

沉淀

转化为标签、规则与参数

电话号码校验

278,407 条规则验证：号码提取 → 归一化 → 区号补全 → 唯一候选才修复

大模型不适合：成本高、输出不确定、难以满足误拦约束

最强模型不等于最佳系统；每种能力应只处理它最擅长、最划算、最可控的样本。

最大的成长：从优化单点指标，转向用业务风险和数据闭环设计系统

做得好的

● 回到任务定义

先判断监督信息是否存在，再决定校准、重标注或重建任务。

● 实验驱动判断

用对照实验排除错误方向，避免只凭经验选择更大模型。

● 构建决策闭环

将模型、规则、选择性路由、人审与难例回流统一设计。

需要提升的

● 实验前置设计

前期探索略散；后续先建立假设树、Benchmark 与停止条件。

● 指标版本治理

统一数据版本、评测子集和指标分母，避免结果口径漂移。

● 泛化与校准

继续补充时间外测试、序数评测、概率校准与线上漂移监控。

下一阶段

短期

统一指标口径
补齐 QWK / L4-5 Recall

中期

主动学习高熵样本
序数目标与轻量融合

长期

统一文档 Benchmark
多任务共享编码器

不是换更大的模型，
而是让系统更准、更轻、更持续。

SUMMARY

让模型输出可解释
让不确定性可管理
让每次反馈都沉淀为系统能力

THANKS

Q&A

彭硕 · 华中科技大学 · 腾讯风控算法实习生

