

从“模型可用” 到“业务可信”

司法风控单据智能校验实践

将不确定的模型输出，转化为可解释、可复核、可持续迭代的业务决策

彭硕

腾讯·风控算法实习生 华中科技大学·网络空间安全

2026.08



INPUT



DECISION



从去年 10 月至今：连续近 11 个月的多模态算法实践

三段经历不是岗位切换，而是一条逐步闭环的成长路径

2025.10 — 2026.03

2026.04 — 2026.05

2026.06 — 至今

京东 AI 安全部

大模型后训练实习生

89 万

多模态 SFT 数据

风险数据构建、多模型投票、Qwen3-VL 全参 SFT 与 GDPO，多目标奖励抑制过度拒答。

训练

京东零售

多模态图像生成算法实习生

F1 95.21%

OCR 选型与部署

商品主图清洗、OCR/VLM 横评、生成效果 Benchmark；从训练转向数据与评测体系。

数据·评测

腾讯

风控算法实习生

4 类

司法单据校验能力

清晰度、文书类型、印章、电话号码；从模型指标进一步走向业务决策闭环。

业务闭环

能力演进

模型训练

数据与评测

任务定义与业务决策

目标：可复用的多模态算法闭环

四类校验能力，服务同一条司法单据有效性链路

01

清晰度五级评估

关键问题

二分类无法表达模糊程度

我的工作

任务重定义 · 弱标注 · VLM 微调

重点项目

02

文书类型识别

关键问题

OCR 错字、旋转与标题错序

我的工作

鲁棒匹配 · 级联路由 · 0.28s/条

重点项目

03

无印章识别

关键问题

浅色/小印章与 2% 负样本

我的工作

三模型融合 · sure/unsure · VLM

横向产出

04

电话号码校验

关键问题

格式混乱且不能误拦

我的工作

提取归一化 · 区号补全 · 硬约束

横向产出

统一命题：风险成本不对称时，如何把不确定信号变成可信决策？

高吞吐、低误拦、可解释：决定了系统必须分层决策

17.4万+

万+ 文书图片 / 日


4

类核心校验任务

低

误拦优先级

误拦真实司法请求的风险通常高于放过存疑样本



模型概率 ≠ 业务风险 | 不确定性不应被强行二分，而应被识别、路由与复核

三个核心模型：按技术难度与答辩篇幅展开

01

重点展开 · 6 页

文书清晰度五级评估

技术难度 ★★★

任务重定义 + 数据构造 + VLM 微调

从二分类双峰分数出发，重建五级序数任务，并构造可训练的数据与模型链路。

02

次重点 · 3 页

无印章识别

技术难度 ★★

多模型融合 + 选择性分类

融合版面、印章检测与视觉先验，通过 sure/unsure 路由控制漏检风险。

03

精简说明 · 2 页

文书类型识别

技术难度 ★

OCR 鲁棒匹配 + 级联

稳定高频类型走快速规则路径，异常样本由 VL 兜底。


篇幅分配遵循技术难度，而不是平均罗列业务需求

文书清晰度五级评估

技术难度最高：原任务没有学习五级质量所需的序数信息

- 01 **问题与关键判断** 为什么二分类分数不能直接切五档
- 02 **任务与数据** 二维可辨识度、弱标注与人工闭环
- 03 **模型架构** Qwen3.5-VL + LoRA + 五级软标签
- 04 **结果与下一步** 过拟合诊断与序数评测体系


ARCHITECTURE PREVIEW



约 6 分钟

关键判断：二分类模型没有学习“模糊程度”，校准也无法补出序数信息

原模型输出



为什么直接切五档不可行？

- 1 训练目标错位** 二分类损失只要求跨过边界，不约束同类内部的质量排序。
- 2 分数不单调** 相近分数可能视觉差异大；视觉相近样本也可能分数差异大。
- 3 校准能力有限** Platt / Isotonic 只能重映射已有信息，不能创造等级 2-4。

因此：先重定义任务与标签，再选择模型。

把“主观清晰度”转化为二维可辨识度，并以人机闭环构造数据

任务定义

$$\text{Quality} = f(\text{unreadable_ratio}, \text{readable_sharpness})$$

不可辨文字比例

决定 Level 3-5

正文中有多少文字已无法辨认

可辨区域锐度

区分 Level 1/2

仍可读文字是否边缘发虚或粘连

只评价正文印刷文字；签名、印章与表格线不计入。

数据闭环

1

规则预标注

OCR 行置信度 + 字数/面积权重

2

漏检补偿

二值化与连通域估计 OCR 未检文字

3

人工校正

标注平台确认五级标签与边界 Case

4


训练采样

1/vfreq 缓解 Level 4/5 长尾

训练 9,850 | 测试 3,283 | 独立 AppID

标注平台将规则、模型与人审连接成可迭代的数据闭环

清晰度五级标注·主流程



文书类型复核

文书类型复核

总数据 11803 | v6 预测分布 (前5): 关于商请协助对有关涉案账户紧急止付的函:3470 / 协助查询财产通知书:3396 / 协助冻结财产通知书:3023 / 关于商请协助对紧急高危预警对象:

显示 333 条 1 / 2 页 每页 200 条

row	appid	category	K	L (人工标注)
52	0303A2011054502052024051306131491532	查询	无法判断	无法判断
110	0309A2011052102212024061914140305500	查询	无法判断	无法判断
143	0105A2002210604027552F22407841344562	止付	无法判断	无法判断
150	0205A2002421278971256F22407871040420	冻结	准确	新类型
158	0301A2011753205082024071019146444264	查询	准确	未命中
179	0105A2002210710205205F22407101909201	止付	准确	新类型
218	0103A200231200063524F22400041514090	止付	准确	新类型
240	0101A2007311760070317073A00101455110	止付	准确	新类型

印章审核与模型对比

印章检测 0804 24831 24021 765 0 45 52 163

统计 有印章 无印章 特定 错误 52修正 VLM修正

全部结果 全部S1 全部类型 全部页数

Stage1: HAS=23827 NO=352 UNSURE=607 | Stage2修正: 52 | VLM判定: yes=163 no=396 | 已标注: 806

#	缩略图	文件名	S1结果	S2结果	最终
0		01kuFp5g16urq0f0gm...	有印章	-	有印章
1		01kueqa3r0h0q716j5j...	有印章	-	有印章
2		01kudn0kfgdsc0p0509...	有印章	-	有印章

平台价值：统一呈现模型中间结果 → 人工快速校正 → 错误 Case 回流为标签、规则与评测集

Qwen3.5-VL + LoRA：用五级概率分布学习业务质量标尺



训练目标

文本 Token: Next-Token CE

等级分布: KL / 分布对齐

软标签: 以五级有序分布表达相邻等级不确定性, 避免边界样本被当作绝对真值。


推理输出

等级 = $\operatorname{argmax} P(L_k)$

连续质量分数 $\hat{q} = \sum p_k \cdot k$

关键设计: 不是让 VLM 自由打分, 而是把输出限制在可校准的五级概率空间。

训练曲线揭示过拟合：当前瓶颈已转向数据泛化与序数评测

**+56%**

最佳点后 Eval Loss 上涨

● 结论 1 | 停止增加 epoch

Train Loss≈0.01、Token Acc=0.996，但验证集恶化；继续拟合只会放大噪声。

● 结论 2 | 重建评测体系

下一步重点看 QWK、MAE、Macro-F1、L4/5 Recall 与概率校准。

项目阶段结论：完成任务定义、数据闭环与模型架构；已定位下一阶段主要矛盾。

无印章识别

技术难度第二：小目标、浅色章与极少负样本共同造成漏检风险

01 模型架构

三路检测信号 + 颜色先验

02 决策与结果

选择性分类 + 切块/VLM 复核



LayoutV2

RT-DETR + Pointer



Layout-L

RT-DETR-L



Seal Detector

ResNet + FPN/PSE



HSV Blob

颜色与几何先验

约 3 分钟

三类模型覆盖不同视觉线索，颜色先验补充浅色印章



融合逻辑 高分直接判有章 | 中分需 Seal/颜色确认 | 低分且无辅助信号判无章 | 其余进入 UNSURE

技术核心不是简单投票，而是让不同模型覆盖版面、弯曲文字与颜色三类互补证据。

选择性分类管理不确定性：先自动处理高置信样本，再升级难例

**100%**

Precision

98.94%

Recall

模型贡献分析

Layout-L 覆盖约 98.5% 的有章检出; V2 独立贡献约 0.2%

下一步：用数据驱动的轻量融合器替代手工阈值，并评估单模型微调。

* Precision / Recall 为高置信自动处理子集口径，正式答辩前与 97.62% 版本统一。

文书类型识别

技术难度第三：核心是把稳定高频模式与长尾异常分开处理

01 级联架构

OCR 快路径 + VL 慢路径

02 关键技术与结果

鲁棒标题匹配, Accuracy 99.99%



约 2 分钟

OCR 快路径 + VL 慢路径：用三层匹配抵抗标题噪声



技术路线由风险、吞吐与确定性共同决定，而不是统一使用大模型

清晰度	VLM 微调	需要学习主观序数标尺
印章	多模型 + VLM 复核	视觉证据互补且漏检成本高
文书类型	OCR 规则 + VL 兜底	高频稳定、长尾复杂
电话号码	正则 + 地理库	高吞吐、可枚举、不能误拦

AI 的三个高杠杆位置

探索

快速验证假设

路由

处理高信息增益难例

沉淀

转化为标签、规则与参数

电话号码校验

278,407 条规则验证：号码提取 → 归一化 → 区号补全 → 唯一候选才修复

大模型不适合：成本高、输出不确定、难以满足误拦约束

最强模型不等于最佳系统；每种能力应只处理它最擅长、最划算、最可控的样本。

当前效果：日均 44 万条业务数据中，三类问题均形成稳定识别能力

最新万条抽检

文书类型识别精准率

100%

印章识别精准率

100%

高置信结果零误拦

无印章文书

765 / 24,831

3.08%

≈ 13,556 条/日

$440,000 \times 765 \div 24,831$

识别缺少有效印章的司法文书

文书类型未命中

70 / 10,000

0.70%

≈ 3,080 条/日

$440,000 \times 70 \div 10,000$

过滤非白名单或需升级复核的文书

严重模糊 L4 + L5

421 / 9,850

4.27%

≈ 18,806 条/日

$440,000 \times (337 + 84) \div 9,850$

Level 4 为 3.4%，Level 5 为 0.9%

分项理论过滤量合计约 3.54 万条/日；考虑问题交叉、样本分布与线上路由，实际去重过滤量需以上线统计为准。

最大的成长：从优化单点指标，转向用业务风险和数据闭环设计系统

做得好的

● 回到任务定义

先判断监督信息是否存在，再决定校准、重标注或重建任务。

● 实验驱动判断

用对照实验排除错误方向，避免只凭经验选择更大模型。

● 构建决策闭环

将模型、规则、选择性路由、人审与难例回流统一设计。

需要提升的

● 实验前置设计

前期探索略散；后续先建立假设树、Benchmark 与停止条件。

● 指标版本治理

统一数据版本、评测子集和指标分母，避免结果口径漂移。

● 泛化与校准

继续补充时间外测试、序数评测、概率校准与线上漂移监控。

下一阶段

短期

统一指标口径
补齐 QWK / L4-5 Recall

中期

主动学习高熵样本
序数目标与轻量融合

长期

统一文档 Benchmark
多任务共享编码器

不是换更大的模型，
而是让系统更准、更轻、更持续。

SUMMARY

让模型输出可解释
让不确定性可管理
让每次反馈都沉淀为系统能力

THANKS

Q&A

彭硕 · 华中科技大学 · 腾讯风控算法实习生

