

# 从“模型可用” 到“业务可信”

## 司法风控单据智能校验实践

将不确定的模型输出，转化为可解释、可复核、可持续迭代的业务决策

彭硕

腾讯·风控算法实习生 华中科技大学·网络空间安全



INPUT



DECISION



# 从去年 10 月至今：连续近 11 个月的多模态算法实践

三段经历不是岗位切换，而是一条逐步闭环的成长路径



能力演进    模型训练    ➡    数据与评测    ➡    任务定义与业务决策    ➡    目标：可复用的多模态算法闭环

# 四类校验能力，服务同一条司法单据有效性链路

01

清晰度五级评估

关键问题

二分类无法表达模糊程度

我的工作

任务重定义 · 弱标注 · VLM 微调

重点项目

02

文书类型识别

关键问题

OCR 错字、旋转与标题错序

我的工作

鲁棒匹配 · 级联路由 · 0.28s/条

重点项目

03

无印章识别

关键问题

浅色/小印章与 2% 负样本

我的工作

三模型融合 · sure/unsure · VLM

横向产出

04

电话号码校验

关键问题

格式混乱且不能误拦

我的工作

提取归一化 · 区号补全 · 硬约束

横向产出

统一命题：风险成本不对称时，如何把不确定信号变成可信决策？

# 高吞吐、低误拦、可解释：决定了系统必须分层决策

17.4万+

万+ 文书图片 / 日


4

类核心校验任务

低

误拦优先级

误拦真实司法请求的风险通常高于放过存疑样本



模型概率 ≠ 业务风险 | 不确定性不应被强行二分，而应被识别、路由与复核

# 三个核心模型：按技术难度与答辩篇幅展开

01

重点展开 · 6 页

## 文书清晰度五级评估

技术难度 ★★★

任务重定义 + 数据构造 + VLM 微调

从二分类双峰分数出发，重建五级序数任务，并构造可训练的数据与模型链路。

02

次重点 · 3 页

## 无印章识别

技术难度 ★★

多模型融合 + 选择性分类

融合版面、印章检测与视觉先验，通过 sure/unsure 路由控制漏检风险。

03

精简说明 · 2 页

## 文书类型识别

技术难度 ★

OCR 鲁棒匹配 + 级联

稳定高频类型走快速规则路径，异常样本由 VL 兜底。


篇幅分配遵循技术难度，而不是平均罗列业务需求

# 文书清晰度五级评估

技术难度最高：原任务没有学习五级质量所需的序数信息

- 01 **问题与关键判断** 为什么二分类分数不能直接切五档
- 02 **任务与数据** 二维可辨识度、弱标注与人工闭环
- 03 **模型架构** Qwen3.5-VL + LoRA + 五级软标签
- 04 **结果与下一步** 过拟合诊断与序数评测体系


## ARCHITECTURE PREVIEW



约 6 分钟

# 关键判断：二分类模型没有学习“模糊程度”，校准也无法补出序数信息

原模型输出



## 为什么直接切五档不可行？

- 1 训练目标错位** 二分类损失只要求跨过边界，不约束同类内部的质量排序。
- 2 分数不单调** 相近分数可能视觉差异大；视觉相近样本也可能分数差异大。
- 3 校准能力有限** Platt / Isotonic 只能重映射已有信息，不能创造等级 2-4。

**因此：先重定义任务与标签，再选择模型。**

# 把“主观清晰度”转化为二维可辨识度，并以人机闭环构造数据

## 任务定义

$$\text{Quality} = f(\text{unreadable\_ratio}, \text{readable\_sharpness})$$

不可辨文字比例

决定 Level 3-5

正文中有多少文字已无法辨认

可辨区域锐度

区分 Level 1/2

仍可读文字是否边缘发虚或粘连

只评价正文印刷文字；签名、印章与表格线不计入。

## 数据闭环

1

规则预标注

OCR 行置信度 + 字数/面积权重

2

漏检补偿

二值化与连通域估计 OCR 未检文字

3

人工校正

标注平台确认五级标签与边界 Case

4

训练采样

1/vfreq 缓解 Level 4/5 长尾

训练 9,850 | 测试 3,283 | 独立 AppID

# 标注平台将规则、模型与人审连接成可迭代的数据闭环

## 清晰度五级标注·主流程



## 文书类型复核

文书类型复核

总数据 11803 | v6 预测分布 (前5): 关于商请协助对有关涉案账户紧急止付的函:3470 / 协助查询财产通知书:3396 / 协助冻结财产通知书:3023 / 关于商请协助对紧急高危预警对象:

显示 333 条 1 / 2 页 每页 200 条

| row | appid                                | category | K    | L (人工标注) |
|-----|--------------------------------------|----------|------|----------|
| 52  | 0303A201105450205204051306131491532  | 查询       | 无法判断 | 无法判断     |
| 110 | 0309A2011052102212024061914140305500 | 查询       | 无法判断 | 无法判断     |
| 143 | 0105A2002210604027552F22407841344562 | 止付       | 无法判断 | 无法判断     |
| 150 | 0205A2002421278971256F22407871040420 | 冻结       | 准确   | 新类型      |
| 158 | 0301A2011753205082024071019146444264 | 查询       | 准确   | 未命中      |
| 179 | 0105A2002210710205205F22407101909201 | 止付       | 准确   | 新类型      |
| 218 | 0103A200231200063524F22400041514090  | 止付       | 准确   | 新类型      |
| 240 | 0101A2002311060470317073400101455110 | 止付       | 准确   | 新类型      |

## 印章审核与模型对比

印章检测 0804 24831 24021 765 0 45 52 163

统计 有印章 无印章 特定 错误 52修正 VLM修正

全部结果 全部S1 全部类型 全部页数

Stage1: HAS=23827 NO=352 UNSURE=607 | Stage2修正: 52 | VLM判定: yes=163 no=396 | 已标注: 896

| # | 缩略图 | 文件名                    | S1结果 | S2结果 | 最终  |
|---|-----|------------------------|------|------|-----|
| 0 |     | 01kuFp5g16urq0f0gm...  | 有印章  | -    | 有印章 |
| 1 |     | 01kueqa3r0h0q716j5j... | 有印章  | -    | 有印章 |
| 2 |     | 01kudn0kfgdsc0p0509... | 有印章  | -    | 有印章 |

平台价值：统一呈现模型中间结果 → 人工快速校正 → 错误 Case 回流为标签、规则与评测集

# Qwen3.5-VL + LoRA：用五级概率分布学习业务质量标尺



## 训练目标

文本 Token: Next-Token CE

等级分布: KL / 分布对齐

软标签: 以五级有序分布表达相邻等级不确定性, 避免边界样本被当作绝对真值。


## 推理输出

等级 =  $\operatorname{argmax} P(L_k)$

连续质量分数  $\hat{q} = \sum p_k \cdot k$

关键设计: 不是让 VLM 自由打分, 而是把输出限制在可校准的五级概率空间。

# 训练曲线揭示过拟合：当前瓶颈已转向数据泛化与序数评测

**+56%**

最佳点后 Eval Loss 上涨

## 结论 1 | 停止增加 epoch

Train Loss≈0.01、Token Acc=0.996，但验证集恶化；继续拟合只会放大噪声。

## 结论 2 | 重建评测体系

下一步重点看 QWK、MAE、Macro-F1、L4/5 Recall 与概率校准。

项目阶段结论：完成任务定义、数据闭环与模型架构；已定位下一阶段主要矛盾。

# 无印章识别

技术难度第二：小目标、浅色章与极少负样本共同造成漏检风险

## 01 模型架构

三路检测信号 + 颜色先验

## 02 决策与结果

选择性分类 + 切块/VLM 复核



LayoutV2

RT-DETR + Pointer



Layout-L

RT-DETR-L



Seal Detector

ResNet + FPN/PSE



HSV Blob

颜色与几何先验

约 3 分钟

# 三类模型覆盖不同视觉线索，颜色先验补充浅色印章



技术核心不是简单投票，而是让不同模型覆盖版面、弯曲文字与颜色三类互补证据。

# 选择性分类管理不确定性：先自动处理高置信样本，再升级难例

**100%**

Precision

**98.94%**

Recall

## 模型贡献分析

Layout-L 覆盖约 98.5% 的有章检出；V2 独立贡献约 0.2%

下一步：用数据驱动的轻量融合器替代手工阈值，并评估单模型微调。

\* Precision / Recall 为高置信自动处理子集口径，正式答辩前与 97.62% 版本统一。

# 文书类型识别

技术难度第三：核心是把稳定高频模式与长尾异常分开处理

## 01 级联架构

OCR 快路径 + VL 慢路径

## 02 关键技术与结果

鲁棒标题匹配, Accuracy 99.99%



约 2 分钟

# OCR 快路径 + VL 慢路径：用三层匹配抵抗标题噪声



# 技术路线由风险、吞吐与确定性共同决定，而不是统一使用大模型

|      |                |              |
|------|----------------|--------------|
| 清晰度  | VLM 微调         | 需要学习主观序数标尺   |
| 印章   | 多模型 + VLM 复核   | 视觉证据互补且漏检成本高 |
| 文书类型 | OCR 规则 + VL 兜底 | 高频稳定、长尾复杂    |
| 电话号码 | 正则 + 地理库       | 高吞吐、可枚举、不能误拦 |

AI 的三个高杠杆位置

探索

快速验证假设

路由

处理高信息增益难例

沉淀

转化为标签、规则与参数

电话号码校验

278,407 条规则验证：号码提取 → 归一化 → 区号补全 → 唯一候选才修复

大模型不适合：成本高、输出不确定、难以满足误拦约束

最强模型不等于最佳系统；每种能力应只处理它最擅长、最划算、最可控的样本。

# 四层校验漏斗：日均 388,180 条输入，预计拦截 38,198 条



# 最大的成长：从优化单点指标，转向用业务风险和数据闭环设计系统

## 做得好的

### ● 回到任务定义

先判断监督信息是否存在，再决定校准、重标注或重建任务。

### ● 实验驱动判断

用对照实验排除错误方向，避免只凭经验选择更大模型。

### ● 构建决策闭环

将模型、规则、选择性路由、人审与难例回流统一设计。

## 需要提升的

### ● 实验前置设计

前期探索略散；后续先建立假设树、Benchmark 与停止条件。

### ● 指标版本治理

统一数据版本、评测子集和指标分母，避免结果口径漂移。

### ● 泛化与校准

继续补充时间外测试、序数评测、概率校准与线上漂移监控。

## 下一阶段

### 短期

统一指标口径  
补齐 QWK / L4-5 Recall

### 中期

主动学习高熵样本  
序数目标与轻量融合

### 长期

统一文档 Benchmark  
多任务共享编码器

不是换更大的模型，  
而是让系统更准、更轻、更持续。

## SUMMARY

让模型输出可解释  
让不确定性可管理  
让每次反馈都沉淀为系统能力

# THANKS

## Q&A

彭硕 · 华中科技大学 · 腾讯风控算法实习生

