

从“模型可用” 到“业务可信”

司法风控单据智能校验实践

将不确定的模型输出，转化为可解释、可复核、可持续迭代的业务决策

彭硕

腾讯·风控算法实习生 华中科技大学·网络空间安全

INPUT



DECISION



从去年 10 月至今：连续近 11 个月的多模态算法实践

三段经历不是岗位切换，而是一条逐步闭环的成长路径

2025.10 — 2026.03

2026.04 — 2026.05

2026.06 — 至今

京东 AI 安全部

大模型后训练实习生

89 万

多模态 SFT 数据

风险数据构建、多模型投票、Qwen3-VL 全参 SFT 与 GDPO，多目标奖励抑制过度拒答。

训练

京东零售

多模态图像生成算法实习生

F1 95.21%

OCR 选型与部署

商品主图清洗、OCR/VLM 横评、生成效果 Benchmark；从训练转向数据与评测体系。

数据·评测

腾讯

风控算法实习生

4 类

司法单据校验能力

清晰度、文书类型、印章、电话号码；从模型指标进一步走向业务决策闭环。

业务闭环

能力演进

模型训练

数据与评测

任务定义与业务决策

目标：可复用的多模态算法闭环

四类校验能力，服务同一条司法单据有效性链路

01

清晰度五级评估

关键问题

二分类无法表达模糊程度

我的工作

任务重定义 · 弱标注 · VLM 微调

重点项目

02

文书类型识别

关键问题

OCR 错字、旋转与标题错序

我的工作

鲁棒匹配 · 级联路由 · 0.28s/条

重点项目

03

无印章识别

关键问题

浅色/小印章与 2% 负样本

我的工作

三模型融合 · sure/unsure · VLM

横向产出

04

电话号码校验

关键问题

格式混乱且不能误拦

我的工作

提取归一化 · 区号补全 · 硬约束

横向产出

统一命题：风险成本不对称时，如何把不确定信号变成可信决策？

高吞吐、低误拦、可解释：决定了系统必须分层决策

17.4万+

万+ 文书图片 / 日


4

类核心校验任务

低

误拦优先级

误拦真实司法请求的风险通常高于放过存疑样本



模型概率 ≠ 业务风险 | 不确定性不应被强行二分，而应被识别、路由与复核

原 XGBoost 能区分“清晰/模糊”，但无法回答“模糊到什么程度”

业务要求：五个有序等级




569

维原始特征

57 维图像/OCR
+ 512 维 CLIP

原 blur_score: 极度双峰



为什么不能直接切 5 档?

- 二分类损失只学习清晰/模糊边界，不约束同类内部排序
- 中间区间数据稀少，分数与视觉严重程度不单调
- 单人标注与相邻等级边界，天然包含主观不确定性


关键判断：问题不在“再找四个阈值”，而在监督信号从未表达等级 2-4。

失败实验逐步排除假设：真正瓶颈是质量监督，而不是模型容量

CLIP 零样本	64.5%	语义对齐特征 ≠ 图像质量特征
CLIP + 线性头	98.36%*	高一致率只是复刻 XGB 弱标签
82 条分歧 Case	29.7%	纯 CLIP 缺少 OCR 质量信息
OCR 置信度分档	≈ 3 档	OCR 对严重模糊仍有强容错
Qwen3-VL 绝对评分	26%	能读出内容就倾向判清晰

* 对 XGB 标签的一致率，不是真实五级准确率


从实验到判断



结论：先重建标签与任务，再讨论模型。

将清晰度重定义为“不可辨比例 + 可辨区域锐度”的两阶段序数任务

二维业务定义



● 维度 1 | unreadable_ratio

正文中有多少文字已无法辨认，决定 Level 3-5；核心是比例而非整体美观。

● 维度 2 | readable_sharpness

仍可辨文字是否发虚、粘连，区分 Level 1/2，避免把“轻微模糊”与“局部缺失”混为一谈。

● 边界规则 | 只评价正文印刷文字

印章、签名、手写和表格线不计入；能靠上下文猜出但笔画不清，仍视为不可辨。

从“主观观感”到“可标注、可学习、可验收”的业务定义

规则预标注 + 漏检补偿 + 人工校正，单人构建 13,133 条五级数据

1

OCR 行质量加权 $0.7 \times \text{字数} + 0.3 \times \text{面积}$

2

不可辨比例 $\text{conf} < 0.8$ 的加权占比

3

漏检补偿

Otsu / 去线 / 连通域


4

人工校正

快捷键平台 + Case 反馈

每次人工反馈都回流为规则或难例，而非只改一条标签

训练集等级分布

**长尾风险**

L4+L5 仅 4.3%
却是业务最关心样本

平方根反频率采样


权重 $1/\sqrt{\text{freq}}$
扩展至 13,523 条

按 AppID 切分，而非随机切分：避免同源模板泄漏


软标签保留相邻等级不确定性，微调将业务标尺写入模型参数

边界样本：Level 2 / 3

硬标签



软标签 (高斯 $\sigma=0.3$)



训练与推理链路




$$\hat{q} = \sum p_k \cdot k \quad | \quad \text{概率不仅用于分类，也用于阈值与拒识}$$

- 直接 Prompt: 缺少稳定业务标尺，输出偏向高质量
- 微调: 固定输出空间、成本可控、可校准、可路由

验证损失在 step 1200 触底：瓶颈已从拟合能力转向数据与泛化

Eval Loss



+56%

step 1200 后 Eval Loss 涨幅

Train Loss ≈ 0.01 、Token Acc = 0.996，但泛化恶化 $\rightarrow$ 典型过拟合

● 动作 1 | 早停与最佳 checkpoint

停止“训练更久”的惯性，固定 step 1200 作为后续评测基线。

● 动作 2 | 换评测问题

Macro-F1、QWK、MAE、L4/5 Recall 与概率校准，而非只看 Token Acc。

当前完成：任务重定义 $\rightarrow$ 数据闭环 $\rightarrow$ 可训练链路 $\rightarrow$ 泛化瓶颈定位

高频类型走 OCR 快路径，只把真正困难样本交给 VL 模型

- OCR 错字
- 繁简/同义词
- 印章水印插入
- 多图错序

全量 VLM 成本高且输出不稳定，因此采用“规则快路径 + 模型慢路径”的选择性级联。



核心取舍 稳定高频模式交给确定性算法；长尾与版面异常才购买更昂贵的模型能力。

≈0.28s

秒 / 主链路

27

个高频白名单类型

45×

快路径与 VL 时延差

三层鲁棒匹配，解决错字、插字、错序与短标题抢占

01 业务归一化

繁→简 50+ 字映射
剥离 ASCII 字母数字
商请/请求/呈请 → 请

消除表面差异

02 自适应编辑距离

≤6 字：精确
7-12: $k=1$ | 13-20: $k=2$
>20: $k=3$

容忍少量 OCR 错字

03 锚点顺序匹配

长标题切 2-4 个锚点
每段 ≥4 字 | 间隔 ≤30 字
容忍水印中文插入



恢复长标题结构

冲突消解

同时收集候选 → 返回归一化后最长标题 → 防止短标题抢占长标题

错误模式驱动，而非堆正则

Accuracy 由 94.59% 提升至 99.99%，主链路单条约 0.28s



迭代不是一次调参，而是持续错误归因



视觉不确定性用模型融合；高吞吐结构化任务用硬规则

无印章识别

负样本约 2% | 浅色章、小印章、多页漏检

1

三模型

LayoutV2 / L / Seal Det

2

颜色几何

HSV / 连通域 / 圆度

3

选择性分类

HAS / NO / UNSURE

4

升级处理

8 块切分 / 多页 VLM

高置信自动处理子集： Precision 100% | Recall 98.94%*

电话号码校验

目标：判无效必须高度确定，存疑则放过

1

提取

国际前缀 / 多号码 / 分机 / 文本

2

归一化

重复前导零 / 区号+手机号

3

补全

法院地理区号 / 本地 7-8 位号

4

约束

候选唯一才修复；非电话特征拒绝

278,407 条验证 | v2.1 最终有效 91.0%*

* 指标口径：印章 97.62%/98.94%、电话 9.0%/11.7% 对应不同版本或子集，答辩前统一。

不为使用 AI 而使用 AI：让每种能力只处理最合适的样本

清晰度	规则预标注 + 人工 + VLM 微调	主观序数任务，需要学习业务标尺
文书类型	OCR 规则快路径 + VL 慢路径	高频稳定、长尾复杂、时延敏感
印章	多模型 sure/unsure + VLM 复核	漏检成本高，允许选择性升级
电话号码	正则 + 地理库 + 硬约束	高吞吐、可枚举、要求可复现

AI 的三个高杠杆位置

- 01 生成候选
快速验证方向，不直接当业务结论
- 02 处理不确定
把成本花在信息增益最高的样本
- 03 沉淀反馈
把人审转成标签、规则与参数

最强模型不等于最佳系统；最佳系统让模型、规则与人审各自处在最优成本区间。

最大的成长：从优化模型指标，转向用业务风险和数据闭环设计系统

做得好的

● 回到问题定义

面对双峰分数，没有停留在切阈值，而是检查监督信息是否存在。

● 实验驱动判断

用失败实验排除特征、容量与 Prompt 假设，保留可复现证据。

● 构建完整闭环

将 OCR、CV、VLM、规则、人审和难例回流组合为可维护链路。

需要提升的

● 实验前置设计

前期探索较散；应先建立假设树、统一 Benchmark 与停止条件。

● 指标版本治理

部分项目存在版本和子集口径差异，需要实验卡片与数据版本化。

● 校准与漂移监控

对概率校准、序数学习、时间外测试与线上漂移实践仍不足。

下一阶段

短期

统一指标口径
补齐 QWK / L4-5 Recall / 校准

中期

主动学习高熵样本
对比 CORAL / EMD 等序数目标

长期

共享文档编码器 + 多任务头
统一 Benchmark 与漂移监控

目标不是换更大的模型，
而是让系统更准、更轻、更可持续。

SUMMARY

让模型输出可解释
让不确定性可管理
让每次反馈都沉淀为系统能力

THANKS

Q&A

彭硕 · 华中科技大学 · 腾讯风控算法实习生

