

一、自我介绍

各位评委老师好，我是彭硕，来自华中科技大学网络空间安全专业，目前在可疑与评级模型团队担任风控算法实习生。今天汇报的主题是“从模型可用到业务可信”。实习期间，我主要面向法院、公安传入的司法单据，完成文书清晰度、印章、文书类型和联系电话等有效性校验。不止步于追求提升离线准确率，我更追求如何让算法在真实业务中做到低误拦、可解释和可持续迭代。

从去年 10 月到现在，我进行了近 11 个月连续的多模态算法实践，这三段经历形成了一条比较清晰的能力演进路径。


第一阶段是在京东 AI 安全部，重点是多模态大模型后训练。我参与了 89 万条 SFT 数据构建、Qwen3-VL 全参数训练以及 GDPO 强化学习，主要解决“如何把模型训练出来”的问题。

第二阶段是在京东零售AIGC团队，工作重心转向训练数据清洗、OCR 部署和生成模型评测，开始关注“如何构造可靠数据、如何评价模型”。

第三阶段来到腾讯风控，进一步面对真实业务约束，工作从模型训练延伸到任务定义、决策路由和人审闭环，也就是“如何让模型真正成为稳定的业务能力”。

二、主要工作总结

法官执行文书（裁定书+通知书+2份工作证）提交银行冻结前，必须做有效性校验和一致性校验。整体处理链路如下



在该业务场景中，在保证不误拦文书的前提下，尽可能的提高拦截率，是最大的挑战。

我的工作聚焦于以下四个子任务：

电话号码有效性校验、印章检测、文书类型检测、清晰度检测。

在最新一批数万条数据集中，各个任务的精准和召回如下：

任务	精准率	召回率	
电话号码校验	100%	-(未检验)	
印章校验	100%	100%（抽样）	
文书类型判断	100%	100%（抽样）	

清晰度检测	100%	-(未检验)	
-------	------	--------	--

目前进度是离线模型开发完成 等待业务开发接入模型,预计线上拒单量如下。

司法单据四任务拦截漏斗

输入 388,180 条 | 各阶段拦截率按总输入计算



具体任务详情：

任务	目标	关键挑战	样例
电话号码校验	拒绝明显打不通号码，验证号码归属	1.输入没有约束，号码变种复杂繁多 2.要保证拒绝号码100%正确 3.判断标准不是电话号码能不能打通，而是"是不是看起来像号码？"	3604764 、 83006499 、 2395104 0591-38125997-10078 → 0591-38125997 承办人座机号码(必填)、209734403722097344、(2025)黑0104民初27259号

清晰度检测	筛选出模糊文书	1.大量文书介于清晰模糊中间，尺度难以量化 2.文书可能部分模糊，部分清晰,需细化颗粒度 3.部分手写体人类清晰可鉴，模型却无法识别。	温岭市公安局 协助查询财产通知书 温公(西)查财字[2026]04344号 财付通支付科技有限公司 因侦查犯罪需要，根据《中华人民共和国民事诉讼法》第一百四十四条之规定，我局派员前往你处查询犯罪嫌疑人 (性别 出生日期) 的财产，请予协助! 财产种类: 财付通 查询线索: 查询涉案微信账号 (wxid_lmg8qq75b1fd12, mf0629888, yu1op5201122, wxid_pziekfdtdzd12, QWERTY12125858) 等在财付通支付科技有限公司开户至今的账号及交易明细等相关信息。 二〇二六年三月 日 此联交协助查询单位
-------	---------	--	---

三、具体实现路径

该部分详细讲解上面提到的关键挑战，以及是如何解决的

3.1 电话号码识别



3.2 印章识别



3.3 文书类型识别



3.4 清晰度检测

该部分是整个工作的重心，将详细讲述，原因如下：


- 1、整个数据漏斗中，因为模糊而需要拒单的样本最多，占比**4.3%**，左右对提高据单率贡献最大、ROI 最高
- 2、实践中发现印章和文书类型识别时出现的疑难样本，有约**37%**是因为文书模糊而难以识别，因此如果前置模糊检测模型能够精准地检出，将大大减轻后续负担。

3.4.1 现状分析

现有日均**38.8**万张法律文书图片，其中存在大量扫描不清、拍照虚焦、公章/水印遮挡、部分字过小导致字符不可辨的文书，无法完成后续的 OCR、一致性校验，应当拒单。

此前已经有xgboost模型（569维特征：57维图像+OCR特征+512维CLIP）在少量标注+数据增强后的数据集上进行二分类任务，大概模糊率**14%**，人工抽检的标注准确率约**90%**。

该方案最大的问题是清晰和模糊的边界难以界定，真实场景下模糊和清晰不是非黑即白的，中间存在大量灰色地带。比如初期与安管就一些case进行了对齐：




三个相似的文书分别被分为了模糊、清晰、模糊

因此，并没有一个很明确，界定清晰的标准来定义清晰和模糊，人的主观感受影响非常大，并且会根据脑中的先验知识辅助识别，此外一些干扰项比如水印、纹路、反光等会对模型识别产生干扰，人会天然剔除掉这些。因此这样直接标注出来的数据质量必然不高，训练出可用的模型更是无稽之谈。在这些case上，xgboost模型结果和安管规则差异非常大，准确率只有**23%**。因此，应该把二分类变成多分类问题，多分类有如下好处：

1. 在模糊和清晰外加入较模糊、较清晰，符合真实数据分布，标注结果更鲁棒。
2. 可以不只按照拒单和不拒单进行处理，不拒单但也不进行后续有效性验证也是一种处理方式
3. 随着模型准确度提升，以及业务规则变化，可以自由选择是否拒单中度模糊或者轻度模糊的

3.4.2 所做尝试

方案	结果	失败原因
Xgboost打分直接五分类	难以制定标准	XGBoost输出的是0-100的blur_score，极度双峰分布（清晰集中在0.05-1，模糊集中在90-99），中间区间数据极少，难以直接切分5档阈值 原模型输出 
CLIP零样本分类（不微调）	64.5%准确率	CLIP训练目标是图文语义匹配，不是图像质量评估，模糊和清晰的cosine相似度差异仅0.006

可辨识度 = 文字不可辨认比例+可辨文字的清晰程度

也就是一个两阶段、两维度的序数任务，而非单一模糊分数。

改为可操作标准：

等级	分类依据	
等级1 — 完全清晰	文字笔画边缘清楚锐利，所有内容轻松可读，无任何模糊感。	
等级2 — 轻微模糊	字迹可辨认，但笔画边缘发虚/粘连/有轻微模糊感，不影响阅读内容。	
等级3 — 局部模糊	部分文字（10%-50%）看不清或难以辨认，其余部分清晰，不影响理解主要内容。	
等级4 — 大部分模糊	超过一半的文字（50%-90%）无法辨认，只能看清少量内容。	
等级5 — 完全无法辨认	90%以上文字不可辨认，几乎或完全无法阅读。	

此外对于一些边界情况单独判别

图片特殊情况（如空白页、严重遮挡、非文书图片等）。

- 印章/签名/手写部分的模糊不计入等级判断，只看正文印刷文字
- 表格线、边框线断裂不算模糊
- 按正文文字的可辨认程度来判断，不是按整体图片美观度
- “可以根据上下文猜出来，但笔画看不清”应算不可辨认。

3.4.4 模型训练

3.4.4.1 模型选择

本任务采用OCR置信度、图像锐度及规则阈值构建五级清晰度判断链路给出预标签。规则方案具备较强可解释性，能够支持初始标签生成和高置信样本筛选。但规则生成的是伪标签，仍然存在OCR低置信不等于视觉模糊的问题,其结果依赖OCR检测完整性和人工阈值。当模糊文字被OCR直接漏检，或低置信度由印章、手写体、生僻字和复杂版面引起时，规则容易产生偏差；

传统分类器能够学习规则特征之间的非线性关系，但通常将整页图像压缩为单一全局特征，容易忽略局部文字模糊，并且输出能力被限制在预定义类别。若后续需要判断模糊区域、受影响字段、退化类型及处理建议，则需要额外训练多个检测和分类模型。

因此，本方案选择具备高分辨率视觉编码、OCR及文档理解预训练能力的VLM作为核心模型。模型能够复用文字区域、字符结构、页面布局和图文对应关系等预训练知识，当前人工标注成本较高，VLM已经具备文档理解能力，适合在少量标注下的迁移学习，能够通过LoRA低成本完成五级质量标准适配。同时，VLM可以理解各个等级的内在联系，而不是像分类器一样硬规则。

具体模型上采用Qwen3.5-9B,该模型使用更新的视觉—语言联合预训练架构，不是后接一个临时视觉模块，而是以统一多模态模型形式训练，原生支持图像输入。并且有更强的OCR和文档能力，更适合中文法律文书、小字和复杂版面。在多个ocr benchmark上超越GPT-5-Nano-2025-08-07、Gemini-2.5-Flash-Lite、Qwen3-VL-30B-A3B等模型。

3.4.4.1 数据构建

因为只有一个标注人员，资源有限，整体采用规则预先打标+ 人工复核打标的方式进行数据构建。


规则预标注

经过多次调整阈值，得到如下详细规则

清晰度五级标签：规则预标注


用于低成本生成初始标签

先估计“多少文字不可辨”，再区分轻微模糊，并补偿 OCR 完全漏检



人工标注

为了更好地可视化标注结果、加快标注人员标注效率，减少无用工作，我借助AI开发了一套标注平台，有**判别原因展示、检索分页、缩放、标注快捷键**等功能。标注人员在平台上根据五档业务规则，确定标签是否正确，并随时将异常情况反馈给我，我立刻调整阈值改善效果（如印章检测的置信度，漏检补偿的规则）。相比之前是维护一个共享的excel表，标注人员去挨个复制粘贴文件名、查询数据，打标签写回excel，最后会议反馈，效率提升了五倍以上。



数据集构成

数据集	数量
训练集(75%，共9,850)	Level 1 (excellent): 5249 (53.3%)
	Level 2 (good): 3352 (34.0%)
	Level 3 (fair): 828 (8.4%)
	Level 4 (poor): 337 (3.4%)


	Level 5 (bad): 84 (0.9%)
测试集(25%)	共 3,283

由于level5和level4的样本数量最少，为防止直接训练会导致模型偏好输出低level，使用平方根反频率过采样，将训练集数据提升到13523条。

标签平滑

考虑到人工与模型都存在标注误差，且五档清晰度本身是序数关系而非互斥类别（相邻档之间没有清晰边界），若用独热硬标签训练，模型会被迫对边界样本过度自信，反而过拟合噪声、丧失泛化。因此采用基于序数距离的高斯标签平滑：以预标签等级为中心、方差 $\sigma^2 \approx 0.3$ （即 $\sigma \approx 0.55$ 档）构造软标签分布，使相邻档获得比远档更高的权重，既保留了序数结构，也把标注不确定性显式注入监督信号。例如 Level 3 的硬标签 $[0,0,1,0,0]$ 平滑为 $[0.001,0.137,0.724,0.137,0.001]$ ——中心仍主导（0.72），相邻档各分到约 0.14，远端近乎为 0。这样做的好处：1）抑制模型对预标签噪声的过拟合；2）允许模型在边界样本上给出“介于两档之间”的概率分布，而非被迫押注单档；3）天然匹配软标签 KL 损失，提升泛化和校准性。

3.4.4.2 模型训练



loss设计

Loss（取 "The quality of the image is" 末尾 "is" 位置 5 个类别 token 的 logits $z \in \mathbb{R}^5$, batch 平均）

$$\mathcal{L} = -\frac{1}{B} \sum_{b=1}^B \sum_{i=0}^4 q_i^{(b)} \log \frac{e^{z_i^{(b)}}}{\sum_{j=0}^4 e^{z_j^{(b)}}}$$


即软标签交叉熵 $H(q, \text{softmax}(z))$ ，等价于 $KL(q \parallel p) + \text{const.}$

训练参数

使用ms-swift框架，对qwen3.5-9B 进行微调

LoRA 配置: rank=8, lr=1e-4, batch=2, grad_accum=4, epochs=3, BF16 + SDPA, 冻结视觉塔和 aligner, 使用显式训练/验证 JSONL。

训练总步数: 2538



在step1200的时候模型便已经收敛，继续训练会过拟合效果更差，及时停止，将模型在验证集上面进行测试，并review结果，查看模型推理与预标签的分歧，纠正初始时候的错误标签，考虑到业务计划采用拒绝第四和第五类，因此重点统计将一二三类归位第四或者第五类的概率，组内则重点统计+1准确率（允许相差一个等级）最终得到如下结果

绝对准确率（和预标签完全一致）	±1 准确率	组内准确率	前→后跨档（好图判差）	后→前跨档
70.42%	98.66%	99.82%	仅 1 条	仅 5 条

3.4.4.3 消融实验

在模型训练的时候，我有如下思考

1. 软标签平滑是否需要，我们的ocr置信度判断规则会存在较大误差吗？直接硬标签会不会可能更好？
2. 直接用qwen的视觉分类器会不会效果更好？感觉目前场景下主要使用的是视觉能力。

对这两个问题，我设计了两个实验，分别是采用硬标签分类和采用qwen3.5的纯视觉头，在同样的训练集和测试集合实验，得到如下结果

实验	exact	±1 准确率	组内准确率*	前→后跨档（好图判差）	后→前跨档
规则预标注（原始 labels）	96.50%	98.05%	97.78%	51 条	22 条
LLM LoRA 软标签	70.42%	98.66%	99.82%	仅 1 条	仅 5 条
LLM LoRA 硬标签	65.03%	97.26%	98.63%	25 条	20 条
纯视觉头	70.36%	98.69%	98.54%	30 条	18 条

- 组内准确率 = 前三类/后两类不互相跨档即算对。±1 准确率 = 偏差≤1 且不犯前→后跨档。

结论为 LLM LoRA（soft）最准。两轮人工复核后，它的前后跨档错误 1 条，后判前5 条。组内准确率 99.82% 一骑绝尘。绝对准确率上 70.42%也超过纯视觉头70.36%成为第一，+1 准确率两者打平。

3.4.5 结果总结

从最终结果来看，针对Qwen3.5-9B做的微调起了作用，整体方案方向得到验证：

1. 模型优点：LLM LoRA（软标签）综合最优，组内准确率99.82%、前后跨档仅1/5条，是唯一把误拦和漏拦同时压到个位数的方案，exact 70.42%也是最高。VLM还理解五档序数递进关系而非互斥硬类别，输出可扩展（模糊区域、受影响字段、处理建议），且LoRA低成本即可重训适配规则变化。
2. 泛化性：复核分歧case发现多数是预标签错、模型对，说明模型学到的是"文字可辨识度"这一连续本质而非规则硬阈值，在水印、手写体、局部模糊等灰色地带仍贴合人工判断。±1准确率98.66%，即使判错也限制在相邻一档内不散，拒单稳定。
3. 为什么硬标签和纯视觉不行：
硬标签把规则预标签的噪声当成确定事实去拟合，exact跌至65.03%、前→后跨档25条；软标签则保留了相邻等级±0.3的合理不确定性。纯视觉头缺少"读字"能力，把整页压成全局特征丢失局部细节，无法理解"表格线断裂不算模糊"等语义规则，还易把印章水印误判为模糊，组内98.54%、跨档30条。
4. 需要做的优化：标签质量是当前最大瓶颈而非模型结构，分歧case中预标签错误占多数，集中在2/3档和4/5档边界。计划用模型替代规则做预标、只复核分歧样本、全量回洗后重训，并补充Level 4/5长尾样本（当前仅337/84条）。
5. 落地路径：主方案是LLM LoRA上线（9B单卡可部署，拒Level 4/5、Level 3转人审）；纯视觉头作为轻量降级或前置粗筛，组成"视觉头分流+LLM复核边界"的两级路由；上线后bad case回流形成迭代闭环。

四、AI 实践与思考

因为我本职工作就是 AI 模型训练，所以 AI 工具对我更多是"效率放大器"而非"能力替代品"。实习期间，AI 主要渗透在我工作的六个环节：

环节	具体用法
编写训练代码	训练脚本、数据清洗、格式转换、评估指标计算等代码的编写与重构
开发标注平台	借助 AI 编程工具快速开发了清晰度标注、印章复核等多套标注平台，从前端交互到后端接口全流程，相比共享 Excel 标注效率提升 5 倍以上
文献调研	快速梳理文档质量评估、IQA 方向的论文脉络与方法对比，定位到"OCR 置信度是文档质量最关键特征"这一关键结论
分析问题	bad case 归因、数据分布分析、实验失败原因排查
设计实验	技术方案枚举对比、消融实验设计、评估指标定义
监控训练	编写训练日志实时监控脚本，追踪 loss 与验证指标变化，异常及时告警

在这个过程中，我总结出几条经验：

1. 用可交互的 HTML 页面/小应用代替 md 文档做汇报与分析。bad case 展示、数据分布探索、实验结果对比这类内容，做成可筛选、可缩放、可下钻的页面，信息密度和沟通效率远高于静态文档，评委和业务方能自己"玩"数据。
- 2.维护个性化的memory.md，让 AI "懂环境、懂业务"。把公司网络环境配置、内部工具的使用方法、数据路径、常用命令、业务术语约定等写进项目记忆，AI 每次对话都自带上下文，避免反复解释，输出质量显著提升。
3. 上下文质量决定输出质量。给 AI 喂错误日志原文、真实数据样例、业务规则条文，而不是一句模糊的需求描述；输入越具体，返工越少。

4. **小步快跑，边写边验。** 复杂任务拆成可独立运行的小模块，AI 每写完一块立刻跑通验证，避免攒出一大坨无法运行的代码再 debug；同时勤 commit，防止 AI 改飞后无法回滚。
5. **关键逻辑必须人工把关。** 数据处理和评估代码“能跑”不等于“算对”，标签对齐、指标口径这类地方 AI 容易埋隐蔽的坑，必须自己 review。
6. **AI 负责广度，人负责判断。** 让 AI 做方案枚举和优缺点罗列很便宜，但拍板要基于业务约束自己判断——比如清晰度任务中“二分类改五分类”的决策，AI 可以给参考，但对业务数据的理解才是决策依据。

五、总结和展望

做得好的地方

1. **完成了从“追求离线指标”到“业务可信”的思维转变。** 清晰度任务中，我没有继续在 XGBoost 阈值上死磕，而是回溯到问题本质——清晰与模糊的标准本身就没有共识，进而推动任务从二分类重定义为五档序数分类，并用 OCR 置信度锚定可操作的标准。这让我认识到：**很多模型问题，本质是任务定义问题。**
2. **建立了全链路的工作视角。** 工作不止于模型训练，向上游延伸到任务定义和数据标准，向下游延伸到标注平台建设、决策路由和人审闭环，最终四个任务在数万条数据上精准率达到 100%。
3. **把数据质量放在模型技巧之前。** 采用“规则预标注 + 人工复核 + 平台化反馈”的数据构建方式，标注效率提升 5 倍，标签质量有了机制性保障，而不是依赖个人细心。
- 4.**在资源约束下找到了效果与成本的最佳平衡。** 这几个任务都达到了99%及以上的精准度，但训练数据仅靠一名标注人员 + 规则预标 + 平台化复核就完成数万条；模型上线后单卡即可部署、推理时延满足 3 秒业务硬约束，未额外占用大显存或多卡资源。即在标注人力、算力、线上延迟三重约束下，拿到了当前可达的最优精度，而非盲目堆参数、堆数据。

做得不好的地方

1. **对“标准不清”这一根因识别偏晚。** 前期在 XGBoost 阈值切分、CLIP 零样本等方案上花费了较多时间试错，如果更早与业务方对齐标注标准、先做任务定义的推演，可以少走约一半的弯路。
2. **与业务方的对齐不够前置和高频。** 初期对“什么样的文书该拒”更多依赖自己的假设，后来才发现安管侧的判断逻辑与模型结果差异很大（一致性仅 23%），这类认知差应该通过早期的 case 对齐会议来消除。
3. **实验管理不够系统。** 部分中间实验的配置、结果记录分散，回头做横向对比时成本较高，缺少统一的实验追踪习惯。
4. **业务价值尚未完全兑现。** 目前离线模型开发完成，但还未接入线上，真实的拒单收益和误拦风险还没有经过线上检验。

待提升点与提升计划

待提升点	提升计划
业务理解深度	从“做好模型”到“算清账”：量化拒单率、误拦成本、人审工时节省，让技术决策以业务 ROI 为锚

工程落地能力	补齐模型部署、推理加速、线上监控的短板，推动清晰度模型完成上线接入
数据闭环意识	上线后建立 bad case 回流机制，形成"标注-训练-上线-回流-迭代"的完整闭环
实验管理规范	建立统一的实验记录模板，关键实验做到配置、数据版本、结果可追溯

长期来看，我希望继续深耕多模态大模型在垂直业务场景的落地——不只是把模型训出来，而是让模型在真实业务约束下成为稳定、可信、可持续迭代的能力。这段实习让我完成了从"训练模型的人"到"对业务结果负责的人"的第一步转变，接下来我会把这条路走扎实。