

刘熠文

☎ 19520263270 ✉ yuwenliu@whu.edu.cn
📅 19903125178
📅 2003-10 📍 河北保定 🌐 汉族 ❤️ 未婚



教育经历

- 武汉大学** 985 2025年09月 - 2027年06月
电子信息 硕士 国家网络安全学院 全日制
GPA: 3.67/4.0 (排名20%)
主修课程: 高级人工智能、高级算法设计、自然语言处理技术及应用、网络安全技术基础、数理统计、物联网工程、高级网络、密码学应用、分布式计算与安全、深度学习原理与实践等
- 西北工业大学** 985 2021年09月 - 2025年06月
信息安全 本科 网络空间安全学院 全日制
GPA: 3.56/4.1 (排名24%)
主修课程: 数据结构、计算机组成原理、操作系统、算法设计、计算机网络、数据库系统、人工智能基础、人工智能与机器学习、密码学、网络安全、编译原理、软件工程、深度学习算法、Python数据分析、大数据基础等

实习经历

- 腾讯科技（深圳）有限公司 —— 风控算法(CDG)** 2026年06月 - 至今
实习概述: 在反洗钱风控团队从事智能风控系统建设与算法研究，主导数据异动归因智能体与风险异常检测模块的设计落地，并开展基于强化学习的特征自动筛选研究。
产出一· 欺诈洗钱风控系统
- 项目背景:** 风险监测、异常归因、策略处置与日常运营长期分散在多张报表和独立系统中，依赖人工查数与流转，效率低、误报多、链路断。目标是建设覆盖全链路的一体化智能风控工作台。
 - 承担任务:**
 - 数据异动归因 Agent:** 自研归因助手并落地为平台级智能体，将归因拆分为确定性计算与模型推断两层，关键数值由 SQL 与指标分解算法产出，大模型仅负责原因推断与业务表达，并通过自动补数、多温度自洽校验与独立复审提升结论可靠性，已覆盖 9 个业务域、40 余个异动节点。
 - 风险异常检测与降误报:** 复盘历史误报工单，归纳分母失真、占比虚高、小基数放大三类误报机理，设计数据成熟度门槛与多角度历史水位投票相结合的判定链，以全历史回溯完成方案选型与阈值确定。
 - 全链路打通与运营模块:** 串联异常发现、案件归因到策略覆盖的跨系统流转，归因结论可直接发起策略建模；建设分环节客诉监测、举证审核在线化与操作审计留痕等运营能力。
 - 项目成果:**
 - 降误报：误报工单由 3747 条降至 3063 条，降幅 18.3%，历史真实异常覆盖率 99.8%，结论经全历史回溯验证。
 - 提效率：指标异动归因由人工 2 至 5 小时缩短至在线数分钟、离线打开即得，漏过案件复盘缩短至秒级，策略覆盖当天闭环。
 - 工程量：累计 116 次代码提交、新增代码 13.3 万行，沉淀 10 篇开发文档与 7 个团队可复用经验库。

产二· “基于强化学习的风控特征自动筛选” 算法研究

- 项目背景:** 风控建模效果高度依赖特征筛选，而特征库规模常达数千个，人工筛选依赖专家经验且难以复现，主流单变量排序方法又无法判断特征间是互补还是重复。目标是把特征筛选从人工试错转为可自动搜索、可复现的算法能力。
- 承担任务:**
 - PPO 特征组合搜索:** 将特征筛选建模为逐步决策问题，以模型效果增益作为单步奖励，使累积回报直接对应最终子集的评估指标，实现算法目标与业务指标一致，并通过动作掩码将业务经验写入策略，在小规模特征集上完成方案验证。
 - 离线 CQL 高维筛选与工程化:** 将动作简化为纳入或跳过的二元决策，设计与特征数量解耦的紧凑状态表达；训练数据由多种启发式策略在 Spark 上并行采集，采用 CQL 离线训练抑制模型对未出现过决策的过高估计；重构特征统计的分布式计算流程，把预筛耗时从小时级压缩到分钟级。
- 项目成果:**
 - 大额支付场景仅用 9 个特征即达到 KS 0.57、AUC 0.84，相比单变量排序基线提升近一倍；社交转账场景在同等特征规模下达到 KS 0.87、AUC 0.96，优于单变量排序与树模型重要度两类方法。
 - 发现并定位训练数据的标签泄露问题，归纳结果字段回填与变量上线时间错位两类成因，剔除后模型区分度仍保持对基线近一倍的优势，沉淀为特征准入的排查规范。

科研经历

- AAAI(CCF-A)发表: MacPrompt: Maracomic-guided Jailbreak against Text-to-Image Models** 2025年01月 - 2025年09月
课题研究员
- 问题背景:** 针对Stable Diffusion等文生图模型中关键词过滤、语义分类器与概念移除机制在跨语言输入下鲁棒性不足等问题，开展生成模型安全评估研究。
 - 研究内容:**
 - 提出 MacPrompt 黑盒攻击框架:** 面向文生图模型安全过滤与概念移除机制在跨语言场景下的鲁棒性缺陷，围绕敏感词识别—跨语言候选筛选—macaromic 替代词构造建立统一攻击流程；先基于黑名单匹配与语义相似度识别触发过滤的敏感词，再利用LLM为每个敏

感词构建多语言翻译/释义候选池，并结合有害性分数与视觉语义相似度进行筛选，最终通过字符级子串切分与重组生成兼具语义保持与文本混淆能力的跨语言对抗提示词，从而在不依赖同义词替换的前提下实现对安全机制的细粒度绕过。

2. **设计基于零阶优化的黑盒优化策略**：针对Stable Diffusion等模型在多语言场景下分词不可逆、难以直接进行token级精确操控的问题，提出基于字符级参数化构造的优化方案；以候选词子串的起始边界参数、结束边界参数及片段排序参数控制替代词生成，并在黑盒设定下采用ZOO（Zeroth-Order Optimization）通过有限差分近似梯度，迭代优化对抗提示词对目标有害概念或禁用对象的激活能力，形成“敏感词定位—候选生成—图像生成—检测反馈—参数更新”的闭环攻击与评测机制，无需访问模型内部参数、梯度或tokenizer。

3. **搭建系统化评测流程**：构建NSFW-200与Object-200两类评测集，在带有黑名单关键词过滤、BERT文本分类器与LatentGuard的Stable Diffusion v2.1，以及ESD、SLD（Max/Strong/Medium）、FMN、SafeGen、DUO、EAP、PromptGuard等多类概念移除防御上开展统一黑盒评测，并与DACA、DiffZOO、ART、Position、MMP-Attack、PGJ、SurrogatePrompt等SOTA基线进行比较。

• **课题成果**：课题相关论文已发表至 **AAAI 2026（CCF-A）**，二作。本方法在安全过滤上最高达到100% BPR，对sex-related与violence-related提示分别取得最高92%和90%的攻击成功率，同时保持最高0.96的语义相似度，验证了现有T2I安全机制在跨语言细粒度扰动下的脆弱性与方法的跨防御泛化能力。

项目经历

面向特定场景的虚假视频协同生成技术

2025年01月 - 2026年04月

项目研究员

- **项目目标**：针对当前电信网络诈骗中日益严峻的虚假合成内容威胁，面向垂直场景视频生成需求，构建高质量领域数据集并完成基座模型LoRA微调，提升模型在特定场景下的语义一致性、主体稳定性与生成质量。
- **承担任务**：
 1. **垂直场景需求分析与数据规划**：面向垂直场景视频生成任务，对基座模型在不同子场景下的生成效果进行系统化测试与对比分析，重点观察其在场景语义表达、主体呈现和画面稳定性等方面的差异，据此确定各类场景的数据集构建规模、样本分布与后续微调重点，为领域化适配提供数据规划依据。
 2. **多模态数据构建与精细化标注**：负责图像数据的定向收集、筛选、清洗与标注，构建“VLM 粗标注 + 人工细标”的数据闭环，提升训练语料的语义准确性与细粒度描述能力。
 3. **视频生成模型LoRA领域微调**：基于Wan2.2 Ti2V 5B开展特定场景文生视频任务的LoRA微调，利用构建的数据集对模型进行领域适配，提升其在目标场景下的文本语义对齐能力、主体一致性与画面生成质量，使模型输出更贴近实际任务需求。
 4. **项目评测**：使用视频评估指标框架VBench对微调模型进行自动化评测。
- **项目成果**：
 - 1.相关成果已申请**计算机软件著作权**
 - 2.成功实现了科研成果的转化应用：自2025年8月起，该技术方案已正式部署于中国联合网络通信有限公司南充市分公司的电信反诈业务场景中。其中生成视频的Overall Consistency、Subject Consistency、Motion Smoothness、等评估指标分别由0.61/0.67/0.58 提升至 0.74/0.81/0.71，说明模型在垂直场景下的语义一致性、主体连续性与动作表达能力得到明显增强。

基于多Agent协同的电商智能客服问答系统

2025年12月 - 2026年06月

项目研究员

- **项目目标**：面向电商客服日均5k-10k咨询场景，构建基于LangGraph的智能客服Agent系统，打通Neo4j图数据库与GraphRAG的结构化/非结构化知识，提升复杂多跳问题的理解、检索与回复能力。
- **承担任务**：
 1. **意图识别**：基于Prompt-template + DeepSeek v3构建客服问题分类链路，围绕业务场景定义5类意图标签，并通过JSON结构化输出约束提升分类结果的可解析性与下游可编排性。项目上线后，基于真实对话日志持续开展难负样本挖掘，将高混淆样本回流到few-shot示例库中，经过3轮模板与样本联合迭代，将意图识别F1从0.79提升至0.91。
 2. **多Agent架构**：基于LangGraph设计面向客服问答场景的Multi-Agent执行框架，形成“意图识别 → 安全护栏 → 子任务分解 → 并行工具调用 → 幻觉拦截”的完整链路。针对复合型、多约束询问对用户问题进行任务拆解，并通过显式节点编排提升流程可控性、可观测性与异常场景下的可干预能力。
 3. **并行检索与查询**：结构化数据走Neo4j Text2Cypher，非结构化数据走GraphRAG，并且预定义了一些Cypher查询语句，用于处理高频率的图数据库查询需求。并行执行后单条复杂询问平均延迟由4.8s降至2.1s。
- **项目成果**：意图识别模块经多轮迭代后F1提升至0.91，图数据库查询链路的Cypher逻辑正确率达到86%，同时完成100+高频Cypher模板与问答防护链路沉淀，提升了复杂客服场景下的回复稳定性与可复用性，并为后续图数据库类项目提供了可复用的实现范式。

荣誉奖项

研究生国家奖学金，本科校级二等奖学金2次，校级优秀学生称号2次

2021-2026

第四届中国研究生网络安全创新大赛 作品赛 一等奖

2025

美国大学生数学建模竞赛 F奖

2024

第二十二届中国研究生数学建模竞赛 二等奖

2025

能力 & 基础

1. **深度学习与工程开发**：精通 Python具备模型搭建—训练—验证—部署全流程经验；深入理解 Transformer原理，能进行模型选型与参数调整；有大模型 LoRA 微调实战经验，熟悉 Linux操作命令和docker部署。。
2. **大模型应用与算法**：熟悉 RAG 流程（检索排序优化、上下文压缩）及知识库问答应用；了解 AI Agent 开发框架与工具调用，能结合业务设计智能体方案；算法与数据结构基础扎实。
3. **英语能力**：CET-6，可流畅阅读英文技术文献与论文；具备技术交流口语能力，能适应国际化团队协作。