


王纪航

1732995940@qq.com | +86-156-5188-2332 | 北京



教育经历

中国科学院自动化研究所 | 硕博连读 (在读)

2021 – 至今 • 北京

专业: 模式识别与智能系统 / 研究方向: 脉冲神经网络的对抗鲁棒性

南京航空航天大学 | 学士 专业: 理学实验班 (信息与计算科学)

2017 – 2021 • 南京

个人总结

累计发表学术论文**7**篇, 其中以第一作者发表**CCF A 类会议论文 2 篇**、**中科院二区/JCR Q1 期刊论文 1 篇**, 申请并授权**国家发明专利 1 项**。研究方向覆盖**模型对抗鲁棒性**、**LLM/VLM 安全评测**、**长时程规划强化学习**。参与 **BrainCog 类脑计算平台**、**大模型安全评测与防护服务平台**等项目。曾在**京东零售视觉生成算法组**实习, 参与**电商商品主图生成任务**的数据构造、评测 benchmark 设计与评估流程优化。

具备基于 Codex 等 AI 编程工具的辅助开发经验。熟悉 LLM、VLM 监督微调、RL 优化、多模态数据构造与评测方法。了解 Agentic RL、模型蒸馏、图像生成。具备良好的理论分析和问题抽象能力。

第一作者论文

- Wang, J., Zhao, D., Chen, R., Zhang, Q., Zeng, Y. **Boosting the Robustness-Accuracy Trade-off of SNNs by Robust Temporal Self-Ensemble. AAAI 2026.**
 - 方法设计: 本工作利用集成对抗防御理论, 提出了一种**训练损失函数**同时优化子模型自身鲁棒性和跨模型的多样性。
 - 研究效果: 提高网络在时域的集成防御能力, 显著优化了网络的鲁棒性-准确率的权衡。
- Wang, J., Zhao D., Chen R., et al. **Towards Reliable Evaluation of Adversarial Robustness for Spiking Neural Networks. CVPR 2026.**
 - 问题定位: 本工作定位到阶跃激活函数的对抗攻击面临的根本问题: **代理梯度估计精度和梯度消失程度的权衡**。
 - 理论方法: 通过**量化梯度消失程度** → **凹性理论分析** → **推导梯度消失程度上界**, 设计了一种高度自适应、自演化梯度近似。
 - 实验结果: 通过实验验证形成理论与实验的闭环, 在各种通用设置下都大幅提高了对抗攻击成功率 (平均约 **10 个百分点**), 解决了阶跃函数的对抗优化问题。
- Wang, J., Zhao, D., Du, C., et al. **Random heterogeneous spiking neural network for adversarial defense. iScience, 2025, 28(6). Cell 旗下子刊.**
 - 方法设计: 本工作利用随机参数防御方法, 设计了一种具有**随机性和异质性神经元参数**的脉冲神经网络架构。
 - 研究效果: 提高脉冲神经网络的对抗防御能力。

主要参与研究

- **Graphing Task State: A Graph-Based Learning Paradigm for Embodied Agent Planning. 共同一作在投.**
 - 研究问题: 本工作针对部分可观察环境 (POMDP) 下 VLM 的长时程规划, 设计了**任务状态图框架**。
 - 监督微调: 通过符号化的环境状态转移构造数据进行 SFT, 让模型学习全局状态以及状态转移。
 - 强化学习: 进一步基于状态图构造了图距离奖励用于 PPO 强化学习训练, 缓解长时程探索中的奖励稀疏问题。
 - 实验结果: 以 Qwen2.5-VL-3B 作为基座进行训练后, 在 EB-Alfred 任务上取得 **91.3** 的任务完成率, 显著超过已有的基于训练的方法以及 Claude-opus-4.5, GPT5.2 等模型。
- **TACA: Think-Action Credit Assignment for LLM Agent Training. 共同一作在投.**
 - 研究问题: 本工作针对 LLM Agent 多步强化学习中 thinking 与 action 信用混淆问题, 提出 **Think-Action Credit Assignment (TACA)**, 将 thinking/action 的 advantage 信号解耦建模。
 - 方法设计: 通过采样过程中特定 thinking 的条件下, 不同 action 的策略偏好和平均回报加权, 计算

thinking token 的优势信号。

- **理论与应用**：进一步理论分析了这种近似优势的策略梯度与理想策略梯度的差异上界。该框架可直接集成到 GiGPO/HGPO 等方法中优化性能。
- Shen, G., Zhao, D., He, X., Feng, L., Dong, Y., Wang, J., ... Zeng, Y. **Neuro-vision to language: Enhancing brain recording-based visual reconstruction and language interaction**. **NeurIPS 2024**, 37, 98083-98110.
 - **研究内容**：本工作训练多模态编码器，将 fMRI 脑信号“翻译”成视觉语义和自然语言。
 - **技术路线**：fMRI → ViT3D → CLIP+VAE 双流对齐 → LLM → 文本理解 / 图像重建。
 - **实验结果**：视觉重建的 CLIP 指标达到了 **97.5%**，CIDEr 从 **49.51 → 83.94**。

实习经历

1. 京东零售-平台产品与研发中心-视觉生成算法组 (2026.4-2026.7)

- 围绕“素材图到商品主图生成”场景，参与电商商品主图生成任务的训练数据构建、模型训练以及测试工作。
- 在数据构造上，设计基于 VLM 的商品主图 caption 自动生成流程，以商品素材图、目标主图及 OCR 识别文本为输入，生成包含布局、商品主体、背景风格及文字内容约束的详细描述。基于商品素材图生成 AI 合成的商品主图，扩充数据规模和质量。
- 在任务测试上，构建商品主图评测 benchmark。整合了基于文本匹配的文字准确率、基于 VLM 的主观打分和 Q-judger 美学评估三种评测指标，构建全自动的文字准确率-主观打分-美学评估流程。
- 在模型训练上，使用 Qwen-Image 生图模型的训练框架对模型进行 SFT。经过 SFT 后模型效果接近 **Banana Pro 2.0**，超过 **Seedream 5.0**。使用 **Diffusion NFT** 对 Qwen-Image 模型进行 RL 训练。

项目经历

1. Brain-inspired Cognitive Intelligence Engine (BrainCog) 智脉 (2023.10-2025.10)

- 参与 BrainCog(<https://github.com/BrainCog-X/Brain-Cog>) 项目，负责类脑计算模型安全组件相关开发，围绕 SNN 隐私保护与对抗鲁棒性开展算法设计和工程实现。
- 在项目框架下实现 SNN 差分隐私训练与对抗鲁棒训练、评估方法，并将算法集成到 BrainCog 平台中。

2. 大模型安全评测与防护服务平台 (2025.2-2026.2)

- 参与 panda-guard(<https://panda-guard.github.io/>) 项目开发，该项目旨在构建将 llm 的攻击、防御、评估集成为一个 pipeline 的 llm 安全测评框架。在 panda-guard 框架中实现 **GCG**、**AutoDAN** 等越狱攻击模块，补全白盒梯度攻击与黑盒文本演化攻击能力，支持 LLM 安全风险的统一评测流程。

获奖与荣誉

- 中国科学院大学 2022-23 学年三好学生
- 全国大学生数学建模竞赛国家二等奖