周愈轩

(+86) 18101450234 · 1684860039@qq.com · https://yuxuan2003.github.io/ ·

教育背景

清华大学, 深圳国际研究生院, 计算机研究所，博士在读 2025.08 - 至今

研究方向为可信 AI，包括多模态内容安全,AIGC 生成内容检测, 师从夏树涛教授

华中科技大学, 网络空间安全学院（启明荣誉班）, 工学学士 2021.09 - 2025.06

rank 2/18, GPA 3.92/4.00, 推免保研清华大学

实习经历

腾讯 CSIG | 元宝　文生图 Prompt 安全改写与自动化评测 2026.06 - 至今

- 参与 T2I Prompt 安全改写模型的 GRPO 训练框架建设，基于 Verl + vLLM Rollout 生成多候选改写结果，提升模型在安全合规与意图保留之间的平衡能力。
- 设计文本侧与图像侧自动化评测 reward，覆盖文本安全、属性保留、最小改写、图像安全、图像保真等维度，并接入 Triton 生图服务与多模态 Judge 服务进行闭环判分。
- 建立 badcase 诊断与切片分析流程，归因 unsafe leakage、over-refusal、semantic drift、style loss 等失败类型，用于指导 reward 调参和训练数据迭代。

字节跳动 | Flow 安全 2025.03 - 2025.09 与 2026.02 - 2026.06

- **构建字节内部多模态自动化评测平台**：覆盖越狱、版权、隐私、内容安全等风险场景，支持 LLM、VLM、T2I、Agent 等目标模型；负责多模态评测算法、自动 Judge 与平台架构重构，服务 Seed、火山、豆包等核心业务。
- **参与 Seed / Seedream 发布前评测工作**：围绕多轮、多模态逻辑诱导、图像生成安全与鲁棒性等场景，建设测例采集、自动化处理、精细化标注、多路检索与 badcase 管理链路，支撑风险发现、指标统计、回归复测与对齐数据沉淀。
- **设计模块化 Agentic Evaluation / Red-Teaming 框架**：将 case 构造、目标模型调用、VLM/LLM Judge、Reward、Metrics、Storage 等能力解耦为可组合模块，由 Orchestrator 统一调度，实现自动化评测、失败归因、hard case mining 与评测轨迹持久化。

科研论文

Improving Deepfake Detection with Reinforcement Learning-Based Adaptive Data Augmentation.
Yuxuan Zhou, Tao Yu, Wen Huang, ZhangYuHeng, Tao Dai, Shu-Tao Xia
Association for the Advancement of Artificial Intelligence (AAAI), 2026

Why does Weak-OOD Help? A Further Step Towards Understanding Jailbreaking VLMs.
As the first author, Under Review. *(ByteDance Security Affiliated)*

Disson: Automated Multimodal Jailbreaking via Cross-Modal Cognitive Dissonance.
As the first author, Under Review. *(ByteDance Security Affiliated)*

Beyond AUC: Test-Time Topology Adaptation for Deployable VLM Jailbreak Detection.
As the first author, Under Review. *(ByteDance Security Affiliated)*

Secure Transfer Learning: Training Clean Model Against Backdoor in Pre-Trained Encoder and Downstream Dataset.
Yechao Zhang, **Yuxuan Zhou**, Tianyu Li, Minghui Li, Shengshan Hu, Wei Luo, Leo Yu Zhang
IEEE Symposium on Security and Privacy (SP), 2025

Breaking barriers in physical-world adversarial examples: Improving robustness and transferability via robust feature.
Yichen Wang, **Yuxuan Zhou**, Ziqi Zhou, Hangtao Zhang, Wei Wan, Shengshan Hu, Minghui Li
Association for the Advancement of Artificial Intelligence (AAAI Oral), 2025

项目经历

深侬科技，校内导师创业项目 2024.10 - 至今

- **AI 生成内容检测平台（作为负责人）**, 检测内容包括人工智能生成内容（AIGC 图像、视频以及语音)、传统数字篡改（如 PS 编辑）以及深度伪造（Deepfake），并搭建了 agent 工作流将所有功能集成。
- **模型内容安全护栏系统（获公安部认证）**, 参与模型的算法研发，通过 RAG、PE、爬虫以及 SAE 技术，对数据集进行增广、重构与清洗，基于 SFT、DPO、OPD 等多阶段训练迭代模型，低误报性能超越 Qwen3Guard。

本科阶段 2021.09 - 2025.06

- 基于联邦学习的医学影像分割系统以及数据隐私保护 **（负责人，国家级大创全院同级唯一）**
- 鹰眼——deepfake 深度人脸伪造检测系统**（负责人，挑战杯以及互联网 + 均进入省赛）**
- 链安卫士——软件供应链漏洞检测系统**（全国大学生信息安全竞赛特等奖，华科首次）**

获奖、社会服务及兴趣爱好

- 教育部推荐竞赛目录中，获得国家级奖项 4 项、省级若干。
- 受邀担任 AAAI'26、ACL'26 等会议审稿人。获得明德科创奖学金沈飞“飞鲨”奖学金等五项奖学金。